

Error estimates of theoretical models: a guide

J Dobaczewski^{1,2}, W Nazarewicz^{1,3,4} and P-G Reinhard⁵

摘要：

本文提供了关于核结构模型不确定度量化的建议与见解。我们讨论了一种简单的统计误差估计方法、评估系统误差的策略，并展示了如何通过相关性分析揭示各观测量之间的相互依赖关系。基本概念通过简单示例进行说明。通过为预测量提供理论误差范围，并利用统计方法研究可观测量之间的相关性，理论可以显著增强实验与核模型之间的反馈效果。

引言：

“请记住，所有模型都是不完全正确的；实际的问题在于，它们能错到何种程度而仍然有用。”[1] 这句话出自统计学家 Box，他是质量控制和贝叶斯推断领域的先驱，这句话同样适用于核多体问题。在核建模中，不确定性无处不在。事实上，受核介质效应强烈影响的核相互作用并不完全为人所知，与可观测量相关的许多算符情况亦是如此。此外，多体方程难以精确求解，这迫使核模型研究者引入简化假设。在涉及物理量理论计算的论文中，进行不确定度估计的需求在原子物理学界早已得到认可。当前状况已在《Physical Review A》的一篇社论中得到了充分描述[2]。

当论文呈现理论计算结果时，应在可行的情况下包含计算的不确定度估计，尤其在以下情形下：

- 1、作者声称具有高精度，或声称改进了先前工作的精度；
- 2、论文的主要目的是与当前或未来的高精度实验测量进行比较；
- 3、论文的主要目的是对已知实验测量结果进行插值或外推。

这里特别指的是用于核结构和动力学的有效相互作用或能量泛函。这些通常拟合大量实验数据。拟合过程中使用的最小二乘法技术，自然可以借助统计（或回归）分析[3,4]中成熟的不确定度估计方法。这是我们至少可以、也应该做的，为理论结果提供误差估计。

除了基本的误差估计外，统计分析还是获取模型深层次理解的有力工具，例如，它可以帮助确定约束弱或强的参数，以及不同可观测量之间的相关性。然而，仅靠纯统计分析是不够的，因为它无法覆盖所谓的系统误差，即建模中缺失的部分。因此，对外推误差的广泛讨论也必须涉及系统误差。不幸的是，系统误差正是那些无法通过系统方法处理的误差。要预见拟合中可能出现的问题，需要对相关的精确理论和近似理论有深入理解。

系统误差和统计误差：

- 统计模型误差通常是可量化的。具体来说，当模型基于经过大规模数据集拟合得到的参数时，拟合的质量就可以作为模型预测统计不确定性的指标。常用的统计误差估计工具是回归分析。第3节将展示如何通过加权最小二乘法估计统计误差。
- 系统模型误差则源于建模不完善：参数化不足、假设错误，以及由于知识有限而缺失的物理机制。在大多数情况下，由于完美（精确、参考）模型不可得，系统误差极难估计。尤其在大规模外推的情况下，没有完美策略可以评估系统误差，因为一些在已知区域不重要的模型特性，可能在新领域被放大，甚至成为主导。第4节将讨论一些常用的系统误差评估方法。

3.1统计误差

考虑一个具有 N_p 个参数 $p=(p_1,...,p_N)$ 的模型，这些参数通过拟合 N_d 个测量可观测量 O_i ($i=1,...,N_d$) 确定。基本步骤如下：定义惩罚函数（penalty function），对参数 p 进行最小化，构建参数协方差矩阵，然后利用协方差矩阵将预测结果的不确定性与参数值的不确定性关联，从而估计预测误差。常用的惩罚函数是 χ^2 目标函数，

误差评估：

$$\chi^2 = \sum_i \frac{(O_i(p) - O_i^{\text{exp}})^2}{O_i^2} \quad O_i^2 = (O_i^{\text{exp}})^2 + (O_i^{\text{num}})^2 + (O_i^{\text{theo}})^2,$$

分子又叫残差，为了分析不同观测量量纲带来的影响引入权重因子： $W_i = \frac{1}{\sqrt{O_i}}$

避免权重因子的任意性，保证建模好坏需要进行归一化： $\frac{\chi^2(p_0)}{N_d - N_p} \longleftrightarrow 1.$

P_0 指代模型参数的最优解，惩罚函数的最小值。

实际含义：你一开始不知道理论误差多大所以：步骤：1、先拟合；2、看残差分布3、调整 O_i ；4、再拟合

如果多个数据集包含：结合能（MeV） 半径（fm） 四极矩， 激发能（MeV） 等。

$$\chi^2 = \sum_i \frac{(O_i - O_i^{\text{exp}})^2}{O_i^2}$$

如果类型不同那么谁的 O_i 小， 谁权重大？ 可以做等权处理。

$$\chi^2 = \sum_{\text{typ}} \sum_{i \in \text{typ}} \frac{(O_i - O_i^{\text{exp}})^2}{O_i^2} \qquad \frac{1}{N_{\text{typ}}} \sum_{i \in \text{typ}} \frac{(O_i(p) - O_i^{\text{exp}})^2}{(\Delta O_i)^2} = \frac{N_d - N_p}{N_d}$$

理解举例： 能级（N_E）， 电偶极矩（N_Q）， 跃迁概率（N_B） 等属于 N_type。

$$N_d = N_E + N_Q + N_{B(E2)}$$

上述的归一化条件不一定都能成立， 当希望在固定采用误差的情况下研究拟合的变化时， 归一化条件会被不可避免地改变。 引入一个全局因子（不改变相对权重）

$$\chi_{\text{norm}}^2(\mathbf{p}_0) = \frac{\chi^2(\mathbf{p}_0)}{s} = N_d - N_p. \qquad O_i \longrightarrow O_i \sqrt{s},$$

如果多个数据集包含：结合能（MeV） 半径（fm） 四极矩， 激发能（MeV） 等。

$$\chi^2 = \sum_i \frac{(O_i - O_i^{\text{exp}})^2}{O_i^2}$$

如果类型不同那么谁的 O_i 小， 谁权重大？ 可以做等权处理。

$$\chi^2 = \sum_{\text{typ}} \sum_{i \in \text{typ}} \frac{(O_i - O_i^{\text{exp}})^2}{O_i^2} \qquad \frac{1}{N_{\text{typ}}} \sum_{i \in \text{typ}} \frac{(O_i(p) - O_i^{\text{exp}})^2}{(\Delta O_i)^2} = \frac{N_d - N_p}{N_d}$$

理解举例： 能级（N_E）， 电偶极矩（N_Q）， 跃迁概率（N_B） 等属于 N_type。

$$N_d = N_E + N_Q + N_{B(E2)}$$

上述的归一化条件不一定都能成立， 当希望在固定采用误差的情况下研究拟合的变化时， 归一化条件会被不可避免地改变。 引入一个全局因子（不改变相对权重）

$$\chi_{\text{norm}}^2(\mathbf{p}_0) = \frac{\chi^2(\mathbf{p}_0)}{s} = N_d - N_p. \qquad O_i \longrightarrow O_i \sqrt{s},$$

最佳参数 p_0

最优参数化 p_0 是使惩罚函数最小化的参数集，特别是使 χ^2 函数取最小值的参数：

$$\chi_0^2 = \chi^2(p_0).$$

- 当拟合涉及多类观测量时，全局模型优化会变得非常复杂。优化过程计算成本高，因为需要进行大量的模型计算。因此，在全局优化前，通常需要对参数及其误差有一个初步估计。一种高效的预优化方法，特别适用于观测量是模型参数的线性函数的情况，是线性回归算法结合奇异值分解 (SVD) 的方法。
- 模型参数的合理取值域：通常，大多数模型参数组合会产生与实际差别很大的观测量。因此，需要将参数空间限制在“**物理上合理**”的域”，即围绕最小值 p_0 附近的区域。

$$\chi_{\text{norm}}^2(p) \leq \chi_{\text{norm}}^2(p_0) + 1$$

由于这个合理区间通常较小，可以将 $\chi^2(p)$ 展开为二阶近似：

$$\chi^2(\mathbf{p}) - \chi_0^2 \approx \sum_{\alpha, \beta=1}^{N_p} (p_\alpha - p_{0,\alpha}) \mathcal{M}_{\alpha\beta} (p_\beta - p_{0,\beta}),$$

$$\mathcal{M}_{\alpha\beta} = \left. \frac{1}{2} \partial_{p_\alpha} \partial_{p_\beta} \chi^2 \right|_{p_0},$$

最佳参数 p_0

最优参数化 p_0 是使惩罚函数最小化的参数集，特别是使 χ^2 函数取最小值的参数：

$$\chi_0^2 = \chi^2(p_0).$$

- 当拟合涉及多类观测量时，全局模型优化会变得非常复杂。优化过程计算成本高，因为需要进行大量的模型计算。因此，在全局优化前，通常需要对参数及其误差有一个初步估计。一种高效的预优化方法，特别适用于观测量是模型参数的线性函数的情况，是线性回归算法结合奇异值分解 (SVD) 的方法。
- 模型参数的合理取值域：通常，大多数模型参数组合会产生与实际差别很大的观测量。因此，需要将参数空间限制在“物理上合理”的域”，即围绕最小值 p_0 附近的区域。

$$\chi_{\text{norm}}^2(p) \leq \chi_{\text{norm}}^2(p_0) + 1$$


由于这个合理区间通常较小，可以将 $\chi^2(p)$ 展开为二阶近似：

$$\chi^2(\mathbf{p}) - \chi_0^2 \approx \sum_{\alpha, \beta=1}^{N_p} (p_\alpha - p_{0,\alpha}) \mathcal{M}_{\alpha\beta} (p_\beta - p_{0,\beta}),$$

$$\mathcal{M}_{\alpha\beta} = \frac{1}{2} \partial_{p_\alpha} \partial_{p_\beta} \chi^2 \Big|_{\mathbf{p}_0},$$

$\mathcal{M}_{\alpha\beta}$ 是 χ^2 在最小值 p_0 处的 Hessian 矩阵（二阶导矩阵）合理参数化 $\mathbf{p}$ 组成的区域可以用置信椭球（confidence ellipsoid）表示：

$$\frac{1}{s} (\mathbf{p} - \mathbf{p}_0) \hat{\mathcal{M}} (\mathbf{p} - \mathbf{p}_0) \leq 1,$$



统计误差

给定一组模型参数 p ，任意观测量 A 都可以在模型中唯一确定为 $A(p)$ 。由于参数 p 存在不确定性（形成一个“置信椭球”），观测量 A 也会随之变化，从而产生不确定度 ΔA 。为了简化，假设 A 对参数依赖较弱，可以在最优点 p_0 附近做线性展开：

$$A(\boldsymbol{p}) \simeq A_0 + \boldsymbol{G}^A \cdot (\boldsymbol{p} - \boldsymbol{p}_0) \quad \text{for} \quad A_0 = A(\boldsymbol{p}_0) \quad \text{and} \quad \boldsymbol{G}^A = \partial_{\boldsymbol{p}} A|_{\boldsymbol{p}_0}.$$

参数权重： $w(p) \propto e^{-\chi^2_{\text{norm}}(p)}$

统计误差公式： $\overline{\Delta A^2} = \sum_{\alpha\beta} G^A_{\alpha} \hat{C}_{\alpha\beta} G^A_{\beta},$

Jacobin 矩阵（和误差成反比）

观测量与参数呈现简单的线性关系，协方差矩阵

$\hat{C} = s\hat{\mathcal{M}}^{-1} = s(\hat{J}^T \hat{J})^{-1}, \qquad \hat{J}_{i\alpha} = \frac{\partial_{p_{\alpha}} \mathcal{O}_i|_{\boldsymbol{p}_0}}{\Delta \mathcal{O}_i}$

一个特例： $A(\boldsymbol{p}) = p_{\alpha} \qquad G^A_{\beta} = \frac{\partial p_{\alpha}}{\partial p_{\beta}} = \delta_{\alpha\beta} \qquad (\Delta p_{\alpha})^2 = \hat{C}_{\alpha\alpha} \qquad \hat{C} = s(J^T J)^{-1} \qquad \Delta p_{\alpha} = \sqrt{s C_{\alpha\alpha}}$

协方差矩阵的对角元就是参数的方差： $C_{\alpha\alpha} = \text{Var}(p_{\alpha})$

非对角元描述参数之间的关联性

值得注意的是，Hessian矩阵

$$\hat{\mathcal{M}} = \hat{J}^T \hat{J},$$

会随着用于约束模型的数据点数 N_d 线性增长。

所有观测量相同: $O_i \equiv O$

所有误差相同: $\Delta O_i \equiv \Delta O$

$$\hat{M}_{\alpha\beta} = \frac{N_d}{(\Delta O)^2} \left(\frac{\partial O}{\partial p_\alpha} \right) \left(\frac{\partial O}{\partial p_\beta} \right)$$

统计误差会随着数据点数增加而减小

如果模型是“完美的”: $\Delta \mathcal{O}_i^{\text{num}} = \Delta \mathcal{O}_i^{\text{the}} = 0$

$$\Delta A = \sqrt{\frac{\Delta A^2}{N_d}} \sim \frac{\Delta \mathcal{O}^{\text{exp}}}{\sqrt{N_d}},$$

数据点增大，参数数量固定，参数误差范围越小。但是当数据过多，系统误差占主导。

当模型不完美、理论误差主导时: $(\Delta \mathcal{O}^{\text{the}})^2 = \frac{N_d}{N_d - N_p} (\mathcal{O}(\mathbf{p}_0) - \mathcal{O}^{\text{exp}})^2.$

残差反映了模型与数据之间的“天然差距”，理论误差无法比这个差距更小。

估计系统误差

理论模型的系统误差是由于缺失的物理机制和/或模型不完善导致的。由于在大多数情况下完美模型不可得，因此系统误差非常难以估计。为了对系统不确定性有一定认识，尤其是在进行外推时，可以采用以下策略：

1. 残差分析 (Analysis of residuals)

研究给定观测量的残差分布。对于完美模型，残差应呈统计分布。然而在实际情况中，通常会看到系统性趋势。这些趋势往往可以帮助我们猜测潜在的缺失物理，具体例子见第4.1节。

2. 模型间依赖性分析 (Analysis of inter-model dependence)

使用一组 N_m 个合理且足够不同的模型 M_j ($j=1, \dots, N_m$)，在这些模型都经过现有数据良好标定，并基于不同理论假设或优化方案的前提下，对某个观测量 O 做预测 O_j 。

假设不同模型引入的偏差是相互独立的，那么系统误差在一定程度上会被随机化。观测量 O 的模型平均预测值可写为：

$$O_m = \frac{1}{N_m} \sum_{j=1}^{N_m} O_j, \quad O_{\text{syst},m} = \frac{1}{N_m} \sum_{j=1}^{N_m} (O_j - O_m)^2,$$

3. 与已有数据比较 (Comparison with existing data)

拟合观测量的系统误差可以通过使用大量数据点优化模型来估计，以保证统计误差较小。然后，计算该类观测量（例如质量或半径）的均方根偏差 O_{rms} 与已知实验数据的差异。属于该类型的预测观测量 O 的系统误差至少应与 O_{rms} 同量级。

4. 综合建议

建议结合上述策略，同时考虑 O_{syst} 和 O_{rms} 。

在估计了系统误差和统计误差之后，预测观测量 O 可写为：

$$O = O \pm O_{stat} \pm O_{syst}.$$

需要再次强调的是，所提出的关于采用误差（以及隐藏系统误差）的分析，并不能完全估计系统误差在外推中的贡献，因为可用数据通常仅约束了模型参数空间的有限区域。

举例：

$$O_i^{(\text{exp})} = \delta(-1)^i + \varepsilon(i), \quad i = 1, 2, \dots, N_d,$$

均方差：

$$\sigma^2 = \frac{1}{N_d} \sum_{i=1}^{N_d} \varepsilon^2(i),$$

模型A：

$$O_i = O_i^1(p) = p_1, \quad N_p = 1$$


模型B：

$$O_i = O_i^2(p) = p_1 + p_2(-1)^i, \quad N_p = 2$$

模型A分析

- 对应典型情况：核模型不完美，实验误差很小
- χ^2 最小化得到 $p_1 = 0$
- 统计误差条件（公式5）得到 $O_1 \approx \sqrt{\delta^2 + \sigma^2} \approx \delta$
- 雅可比矩阵 $\hat{J}_{11} = 1/\delta$ ，协方差矩阵 $(\hat{M}^{-1})_{11} = \delta^2/N_d$
- 与第3.4节讨论一致：统计不确定性随约束模型的数据点 N_d 增多而减小
- 估计的奇偶交错统计误差 $O_{\text{stat}} = \delta/\sqrt{N_d}$ 可非常小（大量数据时）
- **但预测并不准确**：检查模型A残差（见图2(a)）显示残差分布并非统计分布 $\rightarrow$ 存在大系统误差，可估计为 $O_{\text{rms}} = \delta$
- 因此模型A中： $O_{\text{stat}} \ll O_{\text{syst}}$

通过残差模式发现模型A不够完备，于是采用两参数模型B。



$$O_i = O_i^1(p) = p_1, \quad N_p = 1$$

$$\sum_{i=1}^{N_d} \frac{(O_i(p_0) - O_i^{\text{exp}})^2}{O_1^2} = N_d$$

$$\sum_{i=1}^{N_d} r_i^2 = \sum \delta^2 + \sum 2\delta(-1)^i \varepsilon(i) + \sum \varepsilon(i)^2$$

$$\sum \delta^2 = N_d \delta^2$$

$$\sum \varepsilon(i)^2 = N_d \sigma^2$$

$$\sum_{i=1}^{N_d} r_i^2 \approx N_d(\delta^2 + \sigma^2) \quad \frac{N_d(\delta^2 + \sigma^2)}{O_1^2} = N_d$$

$$O_i = O_i^2(p) = p_1 + p_2(-1)^i, \quad N_p = 2$$

模型B分析

- χ^2 最小化得到 $p_1 = 0, p_2 = \delta$
- 条件 (公式5) 得到 $O_1 \approx \sigma$
- 雅可比矩阵: $\hat{J}_{11} = 1/\sigma, \quad \hat{J}_{12} = (-1)^i/\sigma$
- 协方差矩阵 $\hat{M}^{-1} = (\sigma^2/N_d)\hat{I}$ (2×2 单位矩阵)
- 图2(b)显示残差统计分布围绕零 $\rightarrow$ 模型B完美, 误差为统计性: $O_{\text{stat}} = \sigma$

$$r_i = O_i(p_0) - O_i^{\text{exp}} = \delta(-1)^i - [\delta(-1)^i + \varepsilon(i)] = -\varepsilon(i).$$

$$\sum_{i=1}^{N_d} r_i^2 = \sum_{i=1}^{N_d} \varepsilon(i)^2 = N_d \sigma^2.$$

$$\sum_{i=1}^{N_d} \frac{r_i^2}{O_1^2} = N_d \left| \right.$$




TABLE II. Intrinsic Schiff moments S_0 (in e fm^3) of ^{221}Rn , ^{223}Rn , ^{223}Fr , ^{225}Ra , and ^{229}Pa determined in this work for functionals SIII [2], SkM* [3], SkO' [4], SkX_c [5], SLy4 [6], and UNEDF0 [7] (within the BCS method), and D1S [8] and UNEDF0 [7] (within the HFB method).

EDF	method	^{221}Rn	^{223}Rn	^{223}Fr	^{225}Ra	^{229}Pa
SIII	BCS	13.9	6.9	24.0	27.0	37.6
SkM*	BCS	21.6	30.7	32.5	38.9	46.4
SkO'	BCS	11.4	18.3	23.2	31.5	40.9
SkX _c	BCS	6.4	13.8	18.3	23.6	34.6
SLy4	BCS	20.4	26.2	28.8	36.8	46.0
UNEDF0	BCS	10.6	17.2	19.9	27.9	33.4
D1S	HFB	27.6	30.9	34.3	43.4	52.0
UNEDF0	HFB	20.5	23.5	25.1	32.7	32.9

TABLE III. Same as in Table II but for the intrinsic octupole moments Q_0^3 (in 1000 e fm^3), and with results for ^{224}Ra , ^{226}Ra and ^{220}Rn .

EDF	method	^{221}Rn	^{223}Rn	^{223}Fr	^{225}Ra	^{229}Pa	^{224}Ra	^{226}Ra	^{220}Rn
SIII	BCS	0.7041	0.3032	0.9407	0.9515	1.2378	1.0070	0.9396	0.5705
SkM*	BCS	1.1898	1.2682	1.2079	1.3006	1.4098	1.3717	1.2900	1.1070
SkO'	BCS	0.5405	0.7824	0.8689	1.0753	1.3158	0.9970	1.0993	0.4298
SkX _c	BCS	0.3618	0.6461	0.7409	0.8593	1.1719	0.8757	0.8918	0.1406
SLy4	BCS	0.8625	1.0448	1.0263	1.2130	1.4275	1.1674	1.2127	0.7209
UNEDF0	BCS	0.7521	0.8781	0.8743	1.0753	1.1036	1.0288	1.0468	0.6671
D1S	HFB	1.0590	1.1319	1.1176	1.3253	1.5118	1.2736	1.2403	0.8765
UNEDF0	HFB	0.9014	1.0279	0.9883	1.1926	1.0138	1.1183	1.1177	0.9019

In each case, the linear-regression coefficients a and b ,

$$S_0 = a + bQ_0^3,$$

are determined by a minimization of the penalty function $\chi^2 = \sum_i (S_0(i) - a - bQ_0^3(i))^2$,

$$\chi_{\text{norm}}^2 = \frac{\chi^2}{s} \quad \text{for} \quad s = \frac{\chi_0^2}{N_d - N_p},$$

$$\mathcal{C} = s\mathcal{M},$$

TABLE IV. Regression coefficients a and b , Eq. (10), and elements of the covariance matrices, Eq. (13), corresponding to the intrinsic Schiff moments S_0 (in e fm³) correlated with the ²²⁴Ra intrinsic octupole moments Q_0^3 (in 1000 e fm³), determined for ²²¹Rn, ²²³Rn, ²²³Fr, ²²⁵Ra, and ²²⁹Pa. See also Figs. 6–10.

	²²¹ Rn	²²³ Rn	²²³ Fr	²²⁵ Ra	²²⁹ Pa
a	−26.2500	−28.6654	−10.5570	−8.5960	4.9692
b	38.7352	44.8921	32.8702	37.3967	32.1338
$\mathcal{C}_{aa}$	84.8368	145.2036	33.5428	60.1704	180.5238
$\mathcal{C}_{ab}$	−75.3655	−128.9929	−29.7981	−53.4529	−160.3699
$\mathcal{C}_{bb}$	68.2079	116.7422	26.9681	48.3764	145.1393

$$\Delta S_0(\text{the})^2 = \mathcal{C}_{aa} + 2\mathcal{C}_{ab}Q_0^3(\text{exp}) + \mathcal{C}_{bb} \left[Q_0^3(\text{exp})\right]^2. \quad (16)$$

证明:

$$(\Delta S_0)^2 = \sum_{\alpha,\beta} \frac{\partial S_0}{\partial p_\alpha} C_{\alpha\beta} \frac{\partial S_0}{\partial p_\beta} \qquad \begin{matrix} \frac{\partial S_0}{\partial a} = 1 \\ \frac{\partial S_0}{\partial b} = Q_0^3(\text{exp}) \end{matrix} \qquad C = \begin{pmatrix} C_{aa} & C_{ab} \\ C_{ab} & C_{bb} \end{pmatrix}$$

$$\Delta S_0^2 = C_{aa} \cdot 1^2 + 2C_{ab} \cdot 1 \cdot Q_0^3(\text{exp}) + C_{bb} \cdot (Q_0^3(\text{exp}))^2$$

$$C = s \left(J^T J\right)^{-1} \qquad s = \frac{\chi_0^2}{N_d - N_p} \qquad S_0(i) = a + bQ_0^3(i) \qquad J_{i\alpha} = \frac{\partial S_0(i)}{\partial p_\alpha}$$

$$J = \begin{pmatrix} 1 & Q_0^3(1) \\ 1 & Q_0^3(2) \\ \vdots & \vdots \\ 1 & Q_0^3(N_d) \end{pmatrix} \qquad J^T J = \begin{pmatrix} \sum 1 & \sum Q_0^3(i) \\ \sum Q_0^3(i) & \sum (Q_0^3(i))^2 \end{pmatrix} = \begin{pmatrix} N_d & \sum Q_0^3(i) \\ \sum Q_0^3(i) & \sum (Q_0^3(i))^2 \end{pmatrix}$$

$$C = s(J^T J)^{-1}$$

$$(J^T J)^{-1} = \frac{1}{D} \begin{pmatrix} \sum (Q_0^3)^2 & -\sum Q_0^3 \\ -\sum Q_0^3 & N_d \end{pmatrix}$$

$$D = N_d \sum (Q_0^3)^2 - \left(\sum Q_0^3\right)^2$$

$$C_{aa} = s \frac{\sum (Q_0^3)^2}{D}$$

$$C_{bb} = s \frac{N_d}{D}$$

$$C_{ab} = -s \frac{\sum Q_0^3}{D}$$

$$\Delta S_0(\text{exp}) = b \Delta Q_0^3(\text{exp}).$$

$$\Delta S_0(\text{est}) = \sqrt{\Delta S_0(\text{the})^2 + \Delta S_0(\text{exp})^2}.$$

